

## 08 | 最最最重要的集群参数配置（下）

2019-06-20 胡夕

Kafka核心技术与实战

[进入课程 >](#)



讲述：胡夕

时长 10:58 大小 10.05M



今天我们继续来聊那些重要的 Kafka 集群配置，下半部分主要是 Topic 级别参数、JVM 参数以及操作系统参数的设置。

在上一期中，我们讨论了 Broker 端参数设置的一些法则，但其实 Kafka 也支持为不同的 Topic 设置不同的参数值。当前最新的 2.2 版本总共提供了大约 25 个 Topic 级别的参数，当然我们也不必全部了解它们的作用，这里我挑出了一些最关键的参数，你一定要把它们掌握清楚。除了 Topic 级别的参数，我今天还会给出一些重要的 JVM 参数和操作系统参数，正确设置这些参数是搭建高性能 Kafka 集群的关键因素。

## Topic 级别参数

说起 Topic 级别的参数，你可能会有这样的疑问：如果同时设置了 Topic 级别参数和全局 Broker 参数，到底听谁的呢？哪个说了算呢？答案就是 Topic 级别参数会覆盖全局 Broker 参数的值，而每个 Topic 都能设置自己的参数值，这就是所谓的 Topic 级别参数。

举个例子说明一下，上一期我提到了消息数据的留存时间参数，在实际生产环境中，如果为所有 Topic 的数据都保存相当长的时间，这样做既不高效也无必要。更适当的做法是允许不同部门的 Topic 根据自身业务需要，设置自己的留存时间。如果只能设置全局 Broker 参数，那么势必要提取所有业务留存时间的最大值作为全局参数值，此时设置 Topic 级别参数把它覆盖，就是一个不错的选择。

下面我们依然按照用途分组的方式引出重要的 Topic 级别参数。从保存消息方面来考量的话，下面这组参数是非常重要的：

`retention.ms`：规定了该 Topic 消息被保存的时长。

默认是 7 天，即该 Topic 只保存最近 7 天的消息。一旦设置了这个值，它会覆盖掉 Broker 端的全局参数值。

`retention.bytes`：规定了要为该 Topic 预留多大的磁盘空间。和全局参数作用相似，这个值通常在多租户的 Kafka 集群中会有用武之地。当前默认值是 -1，表示可以无限使用磁盘空间。

上面这些是从保存消息的维度来说的。如果从能处理的消息大小这个角度来看的话，有一个参数是必须要设置的，即 `max.message.bytes`。它决定了 Kafka Broker 能够正常接收该 Topic 的最大消息大小。我知道目前在很多公司都把 Kafka 作为一个基础架构组件来运行，上面跑了很多的业务数据。如果在全局层面上，我们不好给出一个合适的最大消息值，那么不同业务部门能够自行设定这个 Topic 级别参数就显得非常必要了。在实际场景中，这种用法也确实是非常常见的。


好了，你要掌握的 Topic 级别的参数就这么几个。下面我来说说怎么设置 Topic 级别参数吧。其实说到这个事情，我是

有点个人看法的：我本人不太赞同那种做一件事情开放给你很多种选择的设计方式，看上去好似给用户多种选择，但实际上只会增加用户的学习成本。特别是系统配置，如果你告诉我只能用一种办法来做，我会很努力地把它学会；反之，如果你告诉我说有两种方法甚至是多种方法都可以实现，那么我可能连学习任何一种方法的兴趣都没有了。Topic 级别参数的设置就是这种情况，我们有两种方式可以设置：


创建 Topic 时进行设置

修改 Topic 时设置

我们先来看看如何在创建 Topic 时设置这些参数。我用上面提到的`retention.ms`和`max.message.bytes`举例。设想你的部门需要将交易数据发送到 Kafka 进行处理，需要保存最近半年的交易数据，同时这些数据很大，通常都有几 MB，但一般不会超过 5MB。现在让我们用以下命令来创建 Topic：


 复制代码

```
1 bin/kafka-topics.sh --bootstrap-server localhost:9092 --cr
```



我们只需要知道 Kafka 开放了 `kafka-topics` 命令供我们来创建 Topic 即可。对于上面这样一条命令，请注意结尾处的 `--config` 设置，我们就是在 `config` 后面指定了想要设置的 Topic 级别参数。

下面看看使用另一个自带的命令 `kafka-configs` 来修改 Topic 级别参数。假设我们现在要发送最大值是 10MB 的消息，该如何修改呢？命令如下：

 复制代码

```
1 bin/kafka-configs.sh--zookeeperlocalhost:2181--entity-
```

总体来说，你只能使用这么两种方式来设置 Topic 级别参数。我个人的建议是，你最好始终坚持使用第二种方式来设置，并且在未来，Kafka 社区很有可能统一使用 `kafka-configs` 脚本来调整 Topic 级别参数。

## JVM 参数

我在专栏前面提到过，Kafka 服务器端代码是用 Scala 语言编写的，但终归还是编译成 Class 文件在 JVM 上运行，因此 JVM 参数设置对于 Kafka 集群的重要性不言而喻。

首先我先说说 Java 版本，我个人极其不推荐将 Kafka 运行在 Java 6 或 7 的环境上。Java 6 实在是太过陈旧了，没有理由不升级到更新版本。另外 Kafka 自 2.0.0 版本开始，已经正式摒弃对 Java 7 的支持了，所以有条件的话至少使用 Java 8 吧。

说到 JVM 端设置，堆大小这个参数至关重要。虽然在后面我们还会讨论如何调优 Kafka 性能的问题，但现在我想无脑给出一个通用的建议：将你的 JVM 堆大小设置成 6GB 吧，这是目前业界比较公认的一个合理值。我见过很多人就是使用默认的 Heap Size 来跑 Kafka，说实话默认的 1GB 有点小，毕竟 Kafka Broker 在与客户端进行交互时会在 JVM 堆上创建大量的 ByteBuffer 实例，Heap Size 不能太小。

JVM 端配置的另一个重要参数就是垃圾回收器的设置，也就是平时常说的 GC 设置。如果你依然在使用 Java 7，那么可以根据以下法则选择合适的垃圾回收器：

如果 Broker 所在机器的 CPU 资源非常充裕，建议使用 CMS 收集器。启用方法是指定-

```
XX:+UseCurrentMarkSweepGC。
```

否则，使用吞吐量收集器。开启方法是指定-

```
XX:+UseParallelGC。
```


当然了，如果你已经在使用 Java 8 了，那么就用默认的 G1 收集器就好了。在没有任何调优的情况下，G1 表现得要比 CMS 出色，主要体现在更少的 Full GC，需要调整的参数更少等，所以使用 G1 就好了。

现在我们确定好了要设置的 JVM 参数，我们该如何为 Kafka 进行设置呢？有些奇怪的是，这个问题居然在 Kafka 官网没有被提及。其实设置的方法也很简单，你只需要设置下面这两个环境变量即可：

KAFKA\_HEAP\_OPTS：指定堆大小。

KAFKA\_JVM\_PERFORMANCE\_OPTS：指定 GC 参数。

比如你可以这样启动 Kafka Broker，即在启动 Kafka Broker 之前，先设置上这两个环境变量：

 复制代码

```
1 $> export KAFKA_HEAP_OPTS=-Xms6g --Xmx6g
2 $> export KAFKA_JVM_PERFORMANCE_OPTS=-server -XX:+Use
3 $> bin/kafka-server-start.sh config/server.properties
```

## 操作系统参数

最后我们来聊聊 Kafka 集群通常都需要设置哪些操作系统参数。通常情况下，Kafka 并不需要设置太多的 OS 参数，但有些因素最好还是关注一下，比如下面这几个：

文件描述符限制

文件系统类型

Swappiness

提交时间

首先是 `ulimit -n`。我觉得任何一个 Java 项目最好都调整下这个值。实际上，文件描述符系统资源并不像我们想象的那样昂贵，你不用太担心调大此值会有什么不利的影响。通常情况下将它设置成一个超大的值是合理的做法，比如 `ulimit -n 1000000`。还记得电影《让子弹飞》里的对话吗：“你和钱，谁对我更重要？都不重要，没有你对我很重要！”。这个参数也有点这么个意思。其实设置这个参数一点都不重要，但不设置的话后果很严重，比如你会经常看到 “Too many open files” 的错误。

其次是文件系统类型的选择。这里所说的文件系统指的是如 ext3、ext4 或 XFS 这样的日志型文件系统。根据官网的测试报告，XFS 的性能要强于 ext4，所以生产环境最好还是



使用 XFS。对了，最近有个 Kafka 使用 ZFS 的[数据报告](#)，貌似性能更加强劲，有条件的话不妨一试。

第三是 swap 的调优。网上很多文章都提到设置其为 0，将 swap 完全禁掉以防止 Kafka 进程使用 swap 空间。我个人反倒觉得还是不要设置成 0 比较好，我们可以设置成一个较小的值。为什么呢？因为一旦设置成 0，当物理内存耗尽时，操作系统会触发 OOM killer 这个组件，它会随机挑选一个进程然后 kill 掉，即根本不给用户任何的预警。但如果设置成一个比较小的值，当开始使用 swap 空间时，你至少能够观测到 Broker 性能开始出现急剧下降，从而给你进一步调优和诊断问题的时间。基于这个考虑，我个人建议将 swappiness 配置成一个接近 0 但不为 0 的值，比如 1。

最后是提交时间或者说是 Flush 落盘时间。向 Kafka 发送数据并不是真要等数据被写入磁盘才会认为成功，而是只要数据被写入到操作系统的页缓存（Page Cache）上就可以了，随后操作系统根据 LRU 算法会定期将页缓存上的“脏”数据落盘到物理磁盘上。这个定期就是由提交时间来确定的，默认是 5 秒。一般情况下我们会认为这个时间太频繁了，可以适当地增加提交间隔来降低物理磁盘的写操作。当然你可能会有这样的疑问：如果在页缓存中的数据在写入到磁盘前机器宕机了，那岂不是数据就丢失了。的确，这种情况数据确实就丢失了，但鉴于 Kafka 在软件层面已经

提供了多副本的冗余机制，因此这里稍微拉大提交间隔去换取性能还是一个合理的做法。

## 小结

今天我和你分享了关于 Kafka 集群设置的各类配置，包括 Topic 级别参数、JVM 参数以及操作系统参数，连同上一篇一起构成了完整的 Kafka 参数配置列表。我希望这些最佳实践能够在搭建 Kafka 集群时助你一臂之力，但切记配置因环境而异，一定要结合自身业务需要以及具体的测试来验证它们的有效性。

## 开放讨论

很多人争论 Kafka 不需要为 Broker 设置太大的堆内存，而应该尽可能地把内存留给页缓存使用。对此你是怎么看的？在你的实际使用中有哪些好的法则来评估 Kafka 对内存的使用呢？

欢迎写下你的思考和答案，我们一起讨论。如果你觉得有所收获，也欢迎把文章分享给你的朋友。

---

# Kafka 核心技术与实战

全面提升你的 Kafka 实战能力

胡夕

人人贷计算平台部总监  
Apache Kafka Contributor



新版升级：点击「 请朋友读」，20位好友免费读，邀请订阅更有**现金**奖励。

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 07 | 最最最重要的集群参数配置（上）

下一篇 09 | 生产者消息分区机制原理剖析

## 精选留言 (29)

写留言




丰富

2019-06-20

G1是jdk9中默认的，jdk8还是需要显式指定的

作者回复: 嗯嗯，笔误了。多谢纠正：)



👍 10



**aoe**

2019-06-20

ulimit -n这个参数说的太好了！如果不设置，单机在Centos7上几百的并发就报 “Too many open files” 了。网上搜索后设置成65535，用JMater压测单机也只能支撑到1000左右的并发，原来这个值可以设置到1000000！《Kafka权威指南》上说Kafka单机可以轻松...



👍 7




**Xiao**

2019-06-20

帅气的胡老师，后边是否会将Kafka数据丢失和消息重复的场景以及解决思路！

作者回复: 会有的，后面有防止消息丢失和重复消费，到时候一起讨论哈



👍 2




吃饭饭

2019-06-20

Java8默认的新生代垃圾回收器是：UseParallelGC，可以用-XX:+PrintCommandLineFlags -version查看，还有如果显示指定 -XX:+UseCurrentMarkSweepGC 的话，会默认开启 -XX:+UseParallelGC

作者回复: 嗯嗯，这点笔误了。Java 9默认的GC收集器才是G1。Java 8应该还是吞吐量收集器。



2




theivanxu

2019-06-20

最近环境中有一台3G堆内存的节点在某个topic handle request的时候一直OOM，调整到5G重启后恢复正常，很想知道如何评判堆内存大小设置的标准。

作者回复: 没有通用的标准，只有一个最佳实践值：6GB。最好还是监控一下实时的堆大小，特别是GC之后的live data大小，通常将heapsize设置成其1.5~2倍就足够了



1



刘朋




2019-06-20

系统会根据LRU算法定期将页缓存上的 脏 数据落盘到物理磁盘上. 这个定期就是由提交时间来确定的,默认是5秒.

这个时间如何设置? 是内核参数吗?

作者回复: 不算内核参数, 是文件系统的参数。你可以查询一下文件系统手册。比如ext4就是commit=Nseconds这样设置



**风中花**

2019-06-20

给老师点个赞! 按时发布! 辛苦



**赌神很低调**

2019-06-24

胡老师, kafka认为写入成功是指写入页缓存成功还是数据刷到磁盘成功算成功呢? 还是上次刷盘宕机失败的问题, 页缓存的数据如果刷盘失败, 是不是就丢了? 这个异常会不会响应给生产者让其重发呢?






**wykkx**

2019-06-23

老师我的kafka的配置文件server.properties 里没有message.max.bytes这个参数，是不是我要手工的加上去

作者回复: 这些参数都是有默认值的，如果没加就是官网中的默认值。




**Geek\_986289**

2019-06-23

老师请问，  
retention.ms  
retention.bytes

这两个参数是不是只要满足一个，Kafka就会开始清消息了？还是需要两个同时满足才会清消息？

作者回复: 满足任何一个就会开始删除消息




**赌神很低调**

2019-06-22

“如果在页缓存中的数据在写入到磁盘前机器宕机了，那岂不是数据就丢失了。的确，这种情况数据确实就丢失了，但鉴于 Kafka 在软件层面已经提供了多副本的冗余机制，因此这里稍微拉大提交间隔去换取性能还是一个合理的做法。“即使提供了副本，这种情况数据也会丢吧？还是说这部分数据会重发？

作者回复: 我的意思是至少还有其他正常的副本可以使用。。。这个副本重启回来后会重新加载日志段，获取到当前前端位移，因此也能感知刚才为成功写入的消息并重新拉取之~~



**电光火石**

2019-06-22


老师，我们开始是用了3台物理机做broker，但是后面因为磁盘空间不够，做了扩容，但是是扩了8台云主机（性能明显不如物理机），按照produce 均匀分发的原则，会不会云主机会拖慢整个集群的处理效率？在我们搭建的时候，尽量机器配置相同？ ...

作者回复: 如果你只有8GB，就不要设置6GB了，酌情调小吧。具体设置方法可以监控堆上的live data，然后大约乘以1.5或2即可。比如你可以手动触发Full GC，然后查看一下堆上存活的数据大小，比如说是1500MB，那么你可以设置



heap size为2.25GB。

没有说一定要配置相同，但是如果某些机器拖慢了整个集群，的确是要为它们做一些调整的。有条件的话可以保持配置一样，至少方面运维。




**闭门造车**

2019-06-22

如果broker设置的是消息留存7天，而topic A设置的是留存10天，那么实际应该是留存10天吧

作者回复: 嗯呢



**文古**

2019-06-21

老师，您好！外网连接线上服务器集群的参数配置是advertised.listeners配置为外网IP吗？如果这个配置为外网的话，集群启动不起来。

作者回复: 有相应的报错信息吗？



**cricket1981**

2019-06-21

kafka streams或者ksql的性能参数调优有什么建议和参考资料吗？

作者回复: Kafka Streams的性能调优建议:

<https://www.confluent.io/blog/optimizing-kafka-streams-applications>

KSQL本专栏不会涉及，目前我也给不出相应的建议，因为我。。。。我也不会🙄



**saup007**


2019-06-21

修改 Topic 级 max.message.bytes，还要考虑以下两个吧？

还要修改 Broker的 replica.fetch.max.bytes 保证复制正常

消费还要修改配置 fetch.message.max.bytes

作者回复: 是的, 您考虑得很全面: )




**明翼**

2019-06-21

胡老师, 有个问题想提前请教下, 就是我们生产环境有个kafka的存储周期因为磁盘大小原因没设置多大, 所以有存在kafka在删除数据的时候, 这些数据可能正在消费, 程序挂死问题, 日志显示kafka协调者死掉了, 或者有的直接一台broker挂了。想请教下两个问题: 一是, 如果...

作者回复: 1. 删除的时候不会顾及consumer的。可能的问  
题就是位移越界导致的位移重置, 比如consumer位移发生  
跳跃的情形

2. 是Coordinator挂掉还是所在broker挂掉? 或者说后者挂  
掉也不一定是Coordinator组件故障导致的吧。最好还是  
给出一些详细信息, 否则不太好评估。




**Alpha**

2019-06-20

老师, kafka-topics.sh那条命令格式好像错乱了, 空格都

不见了

作者回复: 似乎没看到什么问题, 能否详细说说?




**Hello world**

2019-06-20

老师说的无脑配置给jvm heap 6G大小, 这应该也看机器的吧, 现在机器的内存也越来越大, 我们这的机器都是64G 内存, 配了16G的heap, 老师觉得可以优化吗

作者回复: 虽然无脑推荐6GB, 但绝不是无脑推荐>6GB。一个16GB的堆Full GC一次要花多长时间啊, 所以我觉得6GB可以是一个初始值, 你可以实时监控堆上的live data大小, 根据这个值调整heap size。只是因为大内存就直接调整到16GB, 个人觉得不可取。

另外堆越小留给页缓存的空间也就越大, 这对Kafka是好事啊。



**Geek\_Sue**

2019-06-20

胡老师，您好，文章中提到的JVM版本问题，是否有比较好的建议呢？Java版本对于Kafka的性能方面影响大吗？

作者回复: Kafka 2.0已经不支持Java 7了，2.1版本开始初步支持Java 11，但不建议生产环境用11，所以还是使用Java 8吧。

性能方面，如果是Linux平台，性能的差异主要还是Java版本升级带来的差异吧，应该说影响不是太大。

